Зачем матрицу можно заменить *двумя тонкими*

Теорема Эккарта–Янга, один опыт и один результат, который противоречит ожиданию.

Сколько чисел — это одна картинка?

Чёрно-белая фотография 480 × 480 — это таблица из **230 400 чисел.** Именно столько места она занимает.

что понадобится

01 умножение матрицы на вектор

02 что такое ранг (на уровне «зависимые строки»)

03 длина вектора и корень из суммы квадратов

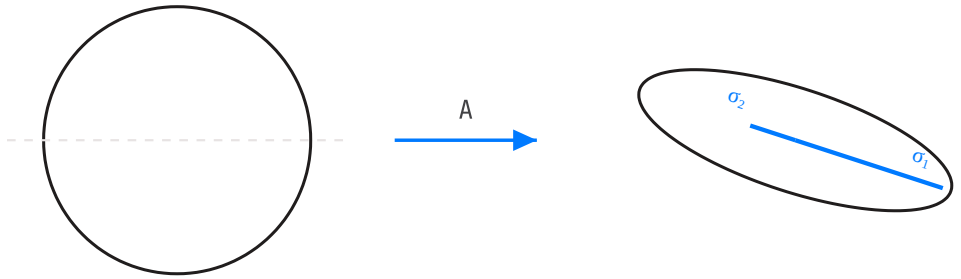
всё остальное выведем по дороге

Матрица — это форма, а не таблица

Возьмём все векторы длины 1 — это окружность (в пространстве — сфера). Умножим каждый на матрицу A и посмотрим, что получится.

Получится эллипсоид. Его полуоси — это и есть **сингулярные числа** $\sigma_1 \geq \sigma_2 \geq \cdots \geq 0$.

Если какая-то полуось равна нулю — матрица **не видит** этого направления. Число ненулевых полуосей и есть ранг.



все направления равны

эллипсоид

никакой магии: это тот же факт, что «образ плоскости — плоскость или прямая»

Ранг и откуда берутся σ

Ранг — размерность образа: сколько независимых направлений матрица реально «видит». Через σ это просто:

$$\operatorname{rang} A = \text{число ненулевых } \sigma_i$$

Сингулярные числа — это корни из собственных чисел матрицы $A^{\top}A$:

$$\sigma_i = \sqrt{\lambda_i(A^{\top}A)}$$

отсюда сразу: σ всегда вещественные и неотрицательные

проверка на пальцах — это и есть домашний пример

A = [1 2; 2 4]. Вторая строка = 2 × первая, значит ранг 1, одно σ равно нулю.

Сумма квадратов всех элементов = $\sigma_1^2 + \sigma_2^2$:

$$1 + 4 + 4 + 16 = 25 = \sigma_1^2, \quad \sigma_1 = 5$$

Проверьте на следующей паре: [3 0; 0 4] → σ = 4 и 3.

Повернуть, растянуть, повернуть

$$A = U \Sigma V^{T}$$ U и V — повороты (ортогональные), Σ — растяжение по осям

МНОЖИТЕЛЬ	ЧТО ДЕЛАЕТ	РАЗМЕР
V^{T}	поворачивает вход на главные оси	n × n
Σ	растягивает ось i в σ_i раз	m × n
U	поворачивает результат в пространство выхода	m × m

Полезная арифметика: **сумма квадратов всех элементов матрицы равна сумме квадратов её σ.** Поэтому σ^2 — это «сколько энергии» сидит в направлении i.

Маленький пример: выгоды пока нет

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}, \quad \sigma_1 = 5, \quad \sigma_2 = 0$$

Разложение: $A = \sigma_1 \, u \, v^T$, где u и v — единичные векторы вдоль $(1, 2)$. Одно слагаемое — и матрица восстановлена точно.

Считаем стоимость: было 4 числа, стало 2 + 2 = 4. Экономии нет.

когда экономия появляется

$$r \cdot (m + n) < m \cdot n$$

Для 2×2 это никогда. Для 1000×1000 — уже при $r < 500$.

То есть сжатие — это про **большие** матрицы, у которых ранг мал по сравнению с размером.

Эккарт–Янг: обрезка оптимальна

Оставим только r первых слагаемых: $A_r = \sigma_1 u_1 v_1^T + \cdots + \sigma_r u_r v_r^T$. Тогда для *любой* матрицы B ранга не больше r:

$$\|A - A_r\| \le \|A - B\| \quad \text{и ошибка равна } \sqrt{(\sigma_{r+1}^2 + \sigma_{r+2}^2 + \cdots)}$$

01 обрезанное разложение — лучшее среди всех матриц ранга r, а не «одно из»

02 ошибку видно заранее: это хвост спектра, считать после обучения не нужно

03 здесь $\|\cdot\|$ — «корень из суммы квадратов всех элементов» (евклидова длина матрицы)

Потерять направление — значит промахнуться

Любая матрица B ранга r обнуляет целое подпространство размерности не меньше n - r — своё **ядро**.

Возьмём единичный вектор z из этого ядра: Bz = 0. Тогда A и B расходятся ровно на Az:

$$\|A - B\| \geq \|(A - B)z\| = \|Az\|$$

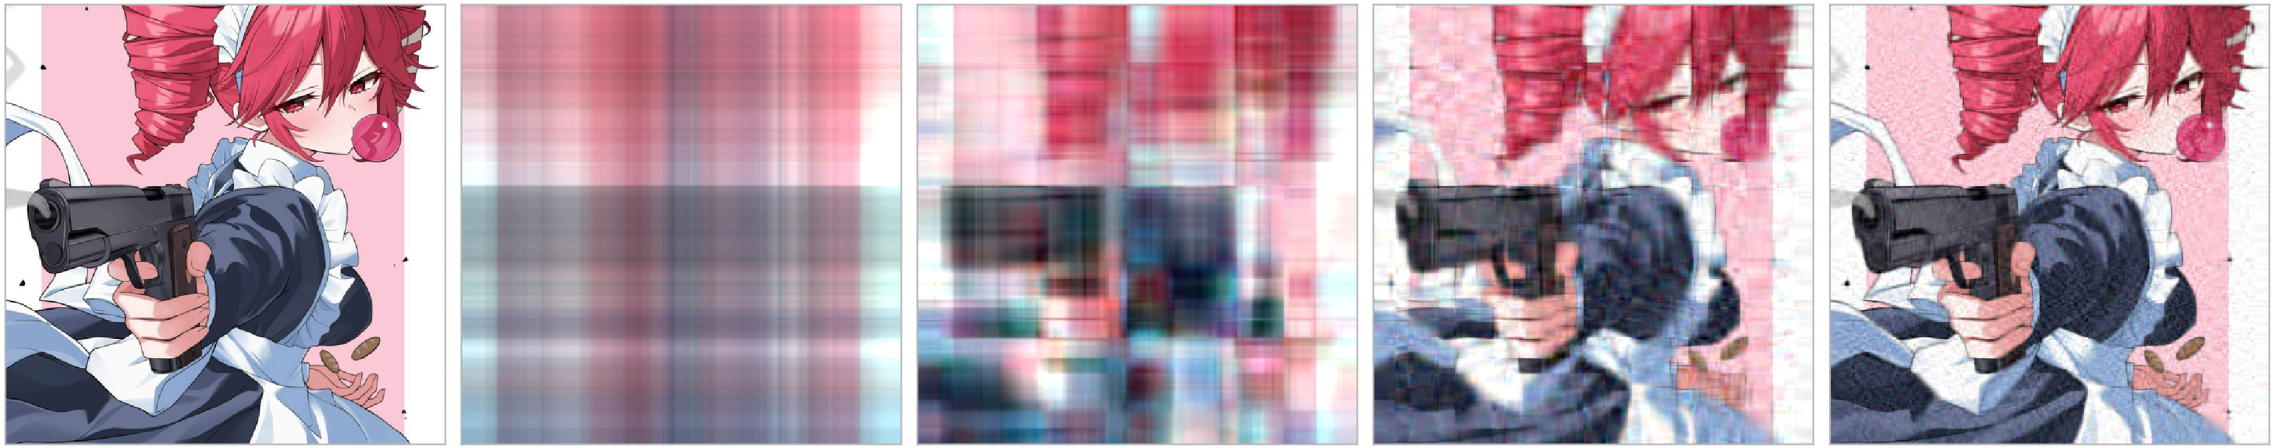
Остаётся выбрать направление, которое B не видит, а A видит сильнее всего — это и есть σ_{r+1}.

Сохранить все направления, оставив только r слагаемых, нельзя — и предыдущая строчка это доказывает. Именно поэтому точную матрицу ранга 100 нельзя заменить матрицей ранга 10.

заметьте: мы не использовали ни данных, ни обучения. Это факт про линейные отображения.

Одна картинка, четыре обрезки

оригинал	ранг 1	ранг 5	ранг 20	ранг 50
691,200 чисел	2,880 чисел	14,400 чисел	57,600 чисел	144,000 чисел
0.0% ошибки	35.7% ошибки	22.6% ошибки	14.0% ошибки	9.8% ошибки



Цветная картинка — это **три матрицы** (R, G, B), каждая сжимается отдельно: 691 200 чисел в оригинале. При ранге 20 их 57 600 — **в 12 раз меньше**, и ошибка 14.0%, ровно та, что даёт формула. При ранге 50 в 4.8 раза меньше, ошибка 9.8%.

[+] ЧАСТАЯ ПУТАНИЦА

σ — это не собственные числа

λ есть только у квадратных матриц и бывают отрицательными или комплексными.

σ есть у любой матрицы, всегда вещественные и неотрицательные.

Для симметричной матрицы они совпадают по модулю: σ = |λ|. Во всех остальных случаях это разные вещи.

пример, где разница видна сразу

B = [0 1 ; 0 0]

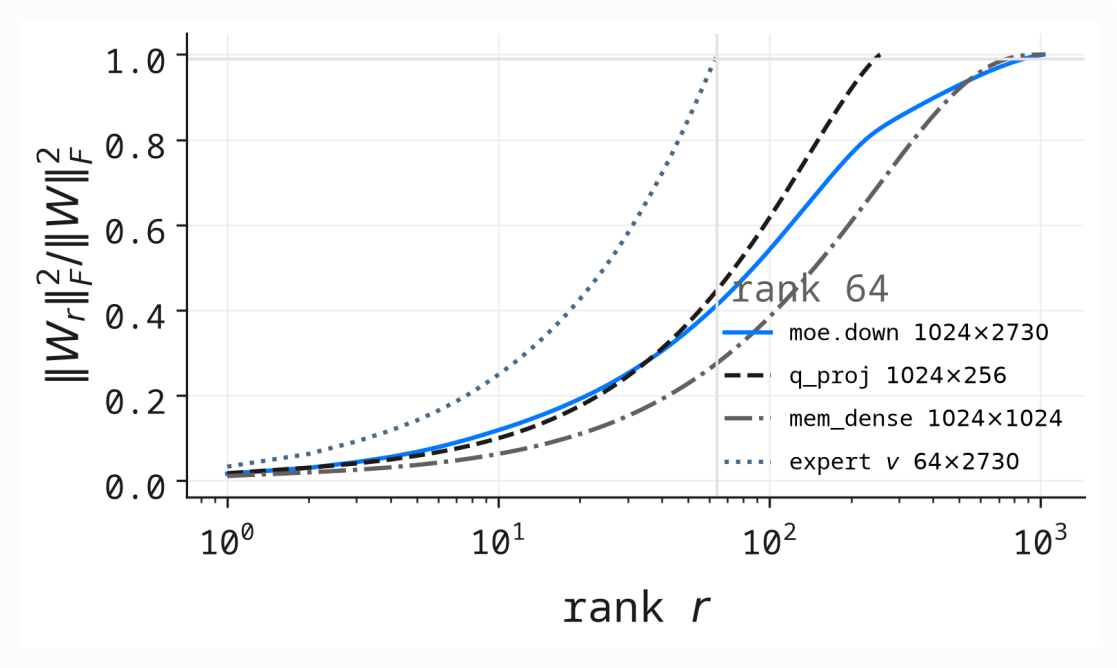
	ЗНАЧЕНИЯ
собственные λ	0 и 0
сингулярные σ	1 и 0

По λ матрица «ничего не делает», но вектор (0,1) она переводит в вектор длины 1. Это видно только через σ.

на экзамене за это снимают баллы — запомните раз и навсегда

Так выглядят матрицы обученной сети

Ожидание не подтверждается



МАТРИЦА	МАССА ПРИ R = 64
moe.down	41%
q_proj	45%
mem_dense	28%
эксперт v	100%

Обученные матрицы не почти низкоранговые: ранг 64 сохраняет лишь 28–45% «энергии».

То есть просто взять и обрезать обученный слой — плохая идея. А последняя строка — исключение, и у него структурная причина.

Сжать готовое ≠ ограничить при обучении

Экспертная матрица имеет ранг 64 по построению: в модели вообще не хранится матрица 64 × 2730 — хранятся две тонкие, и их произведение всегда ранга ≤ 64.

$$W = U\,V^{T}, \quad U: 64\times 64, \quad V: 64\times 2730$$

сжатие готового	ограничение при обучении
Дана фиксированная W. Насколько точно её повторит ранг r?	**Слой сразу ограничен рангом r, и обучение ищет только внутри.**
ответ: плохо	ответ: почти бесплатно

Теорема Эккарта–Янга ограничивает первое. Про второе она не говорит ничего — а именно второе работает в реальных моделях.

Три вывода и одна формула

01 **матрица — это форма;** σ — её полуоси, обрезка оптимальна, ошибка = $\sqrt{(\Sigma_{i>r}\ \sigma_i{}^2)}$

02 **обученные матрицы не низкоранговые:** ранг 64 держит 28–45% энергии — измерено на настоящей сети

03 **сжать ≠ ограничить:** обрезка дорога, обучение внутри семейства почти бесплатно

задача на дом (20 минут)

Возьмите A = [2 0; 0 1]. Найдите σ, постройте A_1, посчитайте ошибку по формуле и проверьте её прямым вычислением.

куда смотреть дальше

SVD и низкоранговые приближения · сжатие изображений · факторизация весов в нейросетях