DORMOUSE · BYTE-LEVEL · 2026

Плотность.

Модель, которая весит как фотография —
и считает быстрее той, что в десять раз больше.

255 МБ 12 000 ТОК/S 1.19 БИТА НА БАЙТ

Все идут вверх.
Мы пошли в другую сторону.

ВЕС МОДЕЛИ

40 ГБ

20B в bf16. Не влезает ни в ноутбук, ни в телефон, ни в одну потребительскую карту.

ТРАФИК НА ТОКЕН

40 ГБ

Декод упирается в память: каждый токен требует прочитать все веса.

ЦЕНА ВХОДА

датацентр

Локально нельзя, приватно нельзя, дешево нельзя.

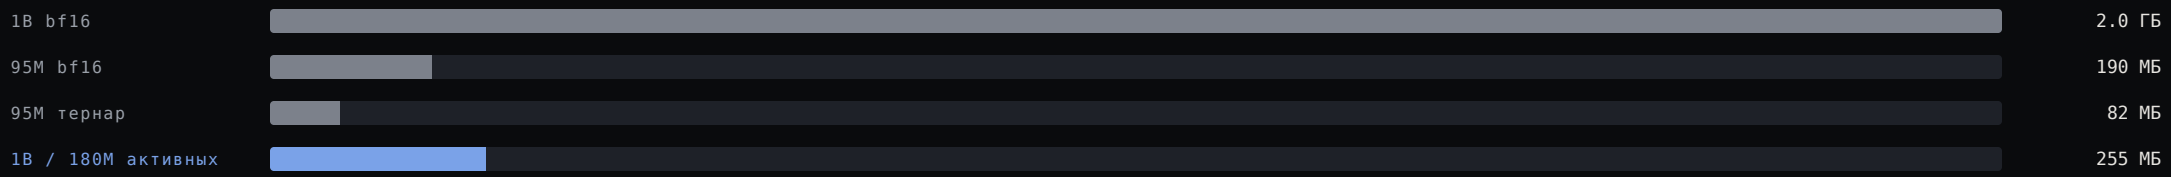
Индустрия продаёт параметры. Пользователь платит байтами и секундами.

1.19 бита на байт

Байтовый трансформер на 95M, обученный на 2.5 ГБ собственного корпуса на одной видеокарте за 8 часов.



Вся модель — 255 МБ



Миллиард параметров, который умещается в письмо. И это не «урезанная» модель — это та же функция, записанная плотнее.

12 000 токенов в секунду

Одна потребительская видеокарта. Без батча, без сервера, без сети.



ВЕС ОДНОГО ВЕСА

2 бита

Тернарный вес читается в два бита, распаковка в регистрах — внутри самого ядра. Декод упирается в память, поэтому меньше байт = быстрее.

В 10 РАЗ БОЛЬШЕ ПРИ 4× СКОРОСТИ

не компромисс

Обычно «больше» значит «медленнее». Здесь наоборот: ёмкость выросла, время на токен упало.

Четыре ступени, каждая измерена отдельно

01

Байт как единица

Никакой токенизации. Модель видит сырые байты — работает на любом языке и на любом коде без словаря.

02

Низкоранговые факторы

Матрицы хранятся как $U \cdot \mathrm{diag}(s) \cdot V^{T}$. 2.7× меньше вычислений при 5% цены качества.

03

Тернарные веса

Три уровня $\{-\alpha, 0, +\alpha\}$, два бита на вес. Анниляция от полной точности к тернару — не с первого шага.

04

Разреженные эксперты

1B хранимых, 180M активных на токен. Ёмкость растёт, вычисления — нет.

Ступени работают только вместе: тернар без факторов не влезает, факторы без разреженности не дают ёмкости.

Одиннадцать механизмов измерены и отвергнуты

МЕХАНИЗМ	ЧТО ДАЛ	ЦЕНА	ВЕРДИКТ
MoE при малом корпусе	1.00×	+25% времени	отказ
Ранг 64 вместо 256	1.95×	+28% качества	отказ
Факторизация attention	2.57×	+27% качества	отказ
Низкоранговый Muon	1.25×	+33% качества	отказ
Меньше шагов оптимизатора	1.08×	+10% качества	отказ
Gated FFN	0.00% парам.	−1.2% качества	в рецепте

Мы не верим в архитектуру — мы её меряем. Поэтому продукт тонкий: в нём осталось только то, что доказало себя на живой модели.

Кодер по PyTorch, который живёт на ноутбуке

РАЗМЕР

255 МБ

Помещается в репозиторий, в контейнер, в дистрибутив.

СКОРОСТЬ

12 000 tok/s

Ответ на страницу — доли секунды. Без очереди и без API.

ПРИВАТНОСТЬ

0 сети

Код не покидает машину. Работает офлайн.

Цель — 40–55% HumanEval на 2B. Это уровень моделей в 10 раз крупнее: Phi-1 показал 50.6% на 1.3B, когда данные отобраны, а не сгреблены.

Три шага, каждый с числом

СЕЙЧАС

Корпус и дистилляция

22 ГБ отобранного кода · 6 млрд токенов

+4 ДНЯ КАРТЫ

2B / 180M активных

тернар + факторы · 255 МБ

+2 ДНЯ

Проверка на своих тестах

300 функций из репозитория · pass@1

Ни один шаг не требует аренды: всё считается на одной видеокарте, которая уже стоит в комнате.

ИТОГ

Меньше не значит слабее. Плотнее — значит быстрее.

БИТ НА БАЙТ	ВЕС МОДЕЛИ	ТОКЕНОВ В СЕКУНДУ
1.19	255 МБ	12 000